

Regular expressions

What regular expressions do you use to extract all the dates in this blurb:
<http://bit.ly/regexercise2> and to put them into the following format YYYY-MM-DD ?

Step 1: Copy and paste the entire text into the test string in regex101:

TEST STRING

Juan•Ponce•de•León•sights•Florida•for•the•first•time,•on•
3.27,•1513↵
Giovanni•da•Verrazzano•explored•the•Atlantic•coast•of•North•
America•under•French•employ,•on•4.17.1524↵
The•Roanoke•Colony•was•found•deserted,•on•8/15/1590↵
John•Smith•founded•the•Jamestown•settlement,•on•5/14,•1607↵
The•Dutch•laid•claim•to•the•territories•of•New•Netherland,•
on•11.11.1614↵
The•Massachusetts•Bay•Colony•founded,•on•3-4-1629|

Step 2: Use the following regular expression to find all the dates, no matter the format, in the text:

`\d{1,2}\. \d{1,2}\. \s?\d{2,4}`

REGULAR EXPRESSION

6 matches (42 steps, 295µs) ⓘ

:/ \d{1,2}\. \d{1,2}\. \s?\d{2,4} / gm

TEST STRING

Juan•Ponce•de•León•sights•Florida•for•the•first•time,•on•
3.27,•1513↵
Giovanni•da•Verrazzano•explored•the•Atlantic•coast•of•North•
America•under•French•employ,•on•4.17.1524↵
The•Roanoke•Colony•was•found•deserted,•on•8/15/1590↵
John•Smith•founded•the•Jamestown•settlement,•on•5/14,•1607↵
The•Dutch•laid•claim•to•the•territories•of•New•Netherland,•
on•11.11.1614↵
The•Massachusetts•Bay•Colony•founded,•on•3-4-1629

EXPLANATION

▼ / \d{1,2}\. \d{1,2}\. \s?\d{2,4} / gm

▼ \d matches a digit (equivalent to [0-9])

{1,2} matches the previous token between 1 and 2 times, as many times as possible, giving back as needed (greedy)

MATCH INFORMATION

Match 1 57-67 3.27,•1513

Match 2 160-169 4.17.1524

QUICK REFERENCE

Step 3: Put into the following format: YYYY-MM-DD

- Under functions, select substitution
- Under regular expressions, put all the values in brackets: `(\d{1,2}).(\d{1,2}).\s?(\d{2,4})`

- Under substitution, put in the following: \$3-\$1-\$2

The screenshot shows the regex101.com interface. The 'REGULAR EXPRESSION' field contains the regex `/ (\d{1,2}) . (\d{1,2}) . \s? (\d{2,4})`. The 'SUBSTITUTION' field contains `$3-$1-$2`. The 'TEST STRING' shows a paragraph of text with dates highlighted. The 'EXPLANATION' panel shows the match details for the first group, and the 'MATCH INFORMATION' panel shows the match details for the first group.

- Now all the dates will be in the correct format:

Juan Ponce de León sights Florida for the first time, on 1513-3-27 Giovanni da Verrazzano explored the Atlantic coast of North America under French employ, on 1524-4-17 The Roanoke Colony was found deserted, on 1590-8-15 John Smith founded the Jamestown settlement, on 1607-5-14 The Dutch laid claim to the territories of New Netherland, on 1614-11-11 The Massachusetts Bay Colony founded, on 1629-3-4

Link: <https://regex101.com/r/ZkTgQN/1>

Converting stop word list from Voyant to R

- Step 1: Copy the entire stop word list from google sheets and insert it into test string in regex 101:
- Step 2: The easiest regular expression to use in this case, is simply a line shift:

REGULAR EXPRESSION

587 matches (1.174 steps, 2ms) ⓘ

⋮ / ↵

/ gm

📄

TEST STRING

2 ↵

3 ↵

4 ↵

aaen ↵

ad ↵

ændr ↵

af ↵

agerschou ↵

akdogan ↵

aldrig ↵


alene ↵

alexandrines ↵

alfred ↵

587:7 – match 587

- Step 3: Click substitution, and insert the following: “, “. Now the stop word list will be in the correct format. Just remember to manually add a “ at the beginning of the first word and end of the last word



Stop word list for R:

"2", "3", "4", "aaen", "ad", "ændr", "af", "agerschou", "akdogan", "aldrig", "alene", "alexandrines", "alfred", "alle", "allerede", "alligevel", "alt", "altid", "ammitzbøll", "amsterdamtraktaten", "amtoft", "anden", "andet", "andre", "annette", "anni", "antonsen", "arbo", "at", "augustforlig", "augustforliget", "augustforligets", "augustforligspartierne", "augustforligspartiernes", "baagø", "baastrup", "baastrup", "bæhr", "bag", "bare", "barfod", "begge", "beskæftigelsesminister", "beskæftigelsesministeren", "beskæftigelsesministerens", "beslutn", "biafra", "birgith", "bjergegaard", "bl.a.", "bladt", "blandt", "blev", "blive", "bliver", "boeg", "bøgsted", "boligforlig", "boligforliger", "boligforliget", "boligsikringsordning", "boligsikringsordningen", "boligsikringsordninger", "boligsikringsordningerne", "bonnesen", "bør", "bové", "bracher", "brinck", "brødkornsordning", "brødkornsordningen", "brødkornsordninger", "brøndsted", "bruno", "brusgaard", "budgetminister", "budgetministeren", "budgetministerens", "buksti", "burde", "ca.", "cd's", "centrums", "charlotte", "clemmens", "co2", "czekoslovakiet", "d.o.n.g", "da", "de", "dem", "den", "denne", "dens", "der", "derefter", "deres", "derfor", "derfra", "deri", "dermed", "derpå", "derived", "det", "dette", "devaluer", "devalueren", "devaluerer", "devaluerer", "de", "df", "dich", "dig", "din", "dine", "disse", "dit", "dobbel", "dobbel", "dobbel", "dog", "donner", "du", "duetoft", "dyrby", "edel", "edele", "efter", "egen", "ej", "eller", "ellers", "elvensø", "en", "end", "endnu", "ene", "eneste", "engangsskat", "engangsskatten", "engangsskatter", "enhedslisten", "enhedslistens", "enhedstelefon", "enhedstelefon", "enhedstelefoner", "enhver", "ens", "enten", "er", "erhvervsminister", "erhvervsministeren", "erhvervsministerens", "et", "eu", "eu's", "euroen", "f.eks.", "få", "faber", "far", "får", "fem", "fik", "fire", "flere", "flest", "fleste", "fødevareminister", "fødevareministeren", "fødevareministerens", "fofa", "for", "før", "foran", "forbrugerminister", "forbrugerministeren", "forbrugerministerens", "fordi", "forrige", "først", "fortsættelsessygekasse", "fortsættelsessygekasser", "fortsættelsessygekasserne", "fortsættelsessygekassernes", "fr.borg", "fra", "frahm", "frahm", "fransgaard", "fransgaards", "freddy", "frevert", "fx", "gæstearbej",


"gasammunion", "geday", "gennem", "gjerskov", "gjorde", "gjort", "glahn", "glistrup", "god", "godt", "gør", "gøre", "gørende", "gottlieb", "grundstigningsskyld", "grundstigningsskylden", "gudme", "guldborg", "hæstorp", "hagensen", "ham", "han", "handelsminister", "handelsministeren", "hans", "har", "harpsoe", "hauch", "havde", "have", "hedeboe", "hej", "hel", "heller", "helligdagslov", "helt", "heltberg", "hen", "hende", "hendes", "henover", "henvisningsoversigt", "henvisningsoversigten", "henvisningsoversigtens", "henvisningsoversigterne", "henvisningsoversigternes", "her", "herefter", "heri", "hermed", "herpå", "hilmar", "hindrup", "homann", "hos", "hun", "husmark", "hvad", "hvem", "hver", "hvilke", "hvilken", "hvilkes", "hvis", "hvor", "hvordan", "hvorefter", "hvorfor", "hvorfra", "hvorhen", "hvor", "hvorimod", "hvornår", "hvorved", "i", "igen", "igennem", "ikke", "imellem", "imens", "imod", "importafgift", "importafgiften", "importafgiftens", "importafgifter", "ind", "indtil", "industriminister", "industriministeren", "industriministerens", "ingen", "integrationsminister", "integrationsministeren", "integrationsministerens", "intet", "ja", "jahn", "jamen", "jane", "jeg", "jer", "jeres", "jerup", "jo", "jobskabelsesloven", "johannesskolen", "junior", "kallesoe", "kan", "karensdag", "karensdage", "karensdagen", "kasseoverskud", "kasseoverskuddet", "kd", "keld", "khader", "kildeskatt", "kildeskatten", "kildeskattens", "kildeskatter", "kindberg", "kjærsgaard", "kling", "kofod", "kolstrup", "kom", "komme", "kommer", "kommunikationsminister", "kommunikationsministeren", "kommunikationsministerens", "kornordning", "kornordningen", "kornordninger", "kosovo", "kreditstramning", "kreditstramningen", "kreditstramninger", "krf", "kristendemokrater", "kristendemokraterne", "kristendemokraternes", "kristine", "kun", "kunne", "lad", "længere", "lærermangel", "lærermangelen", "lahn", "langballe", "langs", "lav", "lave", "lavet", "lawaetz", "legarth", "leroy", "lidegaard", "lidt", "lige", "ligesom", "lille", "lissabontraktaten", "lundholt", "må", "majbrit", "man", "mand", "mange", "markedsminister", "markedsministeren", "markedsministerens", "markedssekretariatet", "markedssekretariatets", "martet", "martinez", "måske", "med", "meget", "mellem", "men", "mens", "mere", "meroms", "meromsen", "merværdiafgift", "merværdiafgiften", "merværdiafgifter", "messerschmidt", "mest", "mig", "miljøminister", "miljøministeren", "miljøministerens", "min", "mindre", "mindst", "mine", "mining", "mit", "mod", "nær", "næste", "næsten", "når", "naser", "ned", "nej", "nemlig", "ni", "nicetraktaten", "niebuhr", "nødgaard", "noer", "nogen", "nogensinde", "noget", "nogle", "nok", "nordek", "nordqvist", "nordvietnam", "nu", "ny", "nyt", "ødt", "oec", "og", "også", "okay", "om", "ømann", "omkring", "omsætningsskat", "omsætningsskatten", "op", "os", "otte", "over", "overalt", "øvrigt", "på", "pålig", "pelle", "pernille", "pga.", "politikasse", "politikassen", "politikasserne", "politikassernes", "poulsgaard", "prehn", "prisstoppet", "prisstoppets", "pristop", "rahbæk", "regeringskonference", "regeringskonferencen", "regeringskonferencens", "reintofts", "retoft", "retsforbundet", "retsforbundets", "ritta", "rohrsted", "rosenkrantz", "rosk", "rune", "så", "sådan", "således", "samme", "sammen", "sams", "sandy", "saunte", "schak", "schengen", "schj", "sdi", "se", "seks", "selv", "selvom", "senere", "ser", "ses", "sf's", "siden", "sig", "sige", "sin", "sine", "sit", "sjursen", "skaarup", "skal", "skattefradragsregel", "skattefradragsreglen", "skattefradragsregler", "skatteminister", "skatteministeren", "skatteministerens", "skattestop", "skattestoppet", "skattestoppets", "skræppenborg", "skrumsager", "skulle", "socialindkomst", "socialindkomsten", "socialindkomster", "sohn", "som", "sophie", "søvndal", "stadig", "statsbanepersonale", "statsbanepersonalet", "statsbanepersonalets", "statsmin.s", "stjernholm", "stor", "store", "storlufthavn", "storlufthavne", "storlufthavnen", "stubbjær", "sundhedsminister", "sundhedsministeren", "sundhedsministerens", "sydamager", "synes", "syntes", "syv", "tag", "tage", "tatovere", "tatoverer", "tatovering", "tatoveringen", "tatoveringer", "temmelig", "theil", "theil", "thi", "thorndahl", "thulesen", "ti", "tidenden", "tidligere", "til", "tilbage", "tindemans", "tit", "to", "tre", "uafhængig", "uafhængige", "uafhængiges", "ud", "uden", "udover", "ufg", "under", "undtagen", "vækstfremmere", "vær", "være", "været", "var", "ved", "velfærdministerens",

"velfærdsminister", "velfærdsministeren", "vestager", "vi", "via", "vibjerg", "vil", "ville", "vivike",
"voigt", "vor", "vore", "vores", "vs", "wedell", "westergaard", "wilhjelm", "yildiz",

Link: <https://regex101.com/r/RSLRZd/1>

Converting stop word list from R to Voyant

- Step 1: Copy and insert the stop word list from R into the test string in Regex101
- Step 2: Insert the following regular expression: “,



- Under substitution, insert the following replacement value: \n

Now the stop word list will be in the correct format for Voyant:

2
3
4
aaen
ad
ændr
af
agerschou
akdogan

Mikkel Vayland Hansen

aldrig
alene
alexandrines
alfred
alle
allerede
alligevel
alt
altid
ammitzbøll
amsterdamtraktaten
amtøft
anden
andet
andre
annette
anni
antonsen
arbo
at
augustforlig
augustforliget
augustforligets
augustforligspartierne
augustforligspartiernes
baagø
baastrup
baastrup
bæhr
bag
bare
barfod
begge
beskæftigelsesminister
beskæftigelsesministeren
beskæftigelsesministerens
beslutn
biafra
birgith
bjergegaard
bl.a.
bladt
blandt
blev
blive
bliver
boeg
bøgsted

Mikkel Vayland Hansen

boligforlig
boligforliger
boligforliget
boligsikringsordning
boligsikringsordningen
boligsikringsordninger
boligsikringsordningerne
bonnesen
bør
bové
bracher
brinck
brødkornsordning
brødkornsordningen
brødkornsordninger
brøndsted
bruno
brusgaard
budgetminister
budgetministeren
budgetministerens
buksti
burde
ca.
cd's
centrums
charlotte
clommensen
co2
czekoslovakiet
d.o.n.g
da
de
dem
den
denne
dens
der
derefter
deres
derfor
derfra
deri
dermed
derpå
derved
det
dette

devaluering
devalueringen
devalueringer
devalueringerne
df
dich
dig
din
dine
disse
dit
dobbeltslutning
dobbeltslutningen
dobbeltslutninger
dog
donner
du
duetoft
dyrby
edel
edele
efter
egen
ej
eller
ellers
elvensø
en
end
endnu
ene
eneste
engangsskat
engangsskatten
engangsskatter
enhedslisten
enhedslistens
enhedstelefon
enhedstelefon
enhedstelefoner
enhver
ens
enten
er
erhvervsminister
erhvervsministeren
erhvervsministerens
et

Mikkel Vayland Hansen

eu

eu's

euroen

f.eks.

få

faber

far

får

fem

fik

fire

flere

flest

fleste

fødevareminister

fødevareministeren

fødevareministerens

fofa

for

før

foran

forbrugerminister

forbrugerministeren

forbrugerministerens

fordi

forrige

først

fortsættelsessygekasse

fortsættelsessygekasser

fortsættelsessygekasserne

fortsættelsessygekassernes

fr.borg

fra

frahm

frahm

fransgaard

fransgaards

freddy

frevert

fx

gæstearbej

gasammunion

geday

gennem

gjerskov

gjorde

gjort

glahn

Mikkel Vayland Hansen

glistrup
god
godt
gør
gøre
gørende
gottlieb
grundstigningsskyld
grundstigningsskylden
gudme
guldberg
hæstorp
hagensen
ham
han
handelsminister
handelsministeren
hans
har
harpsøe
hauch
havde
have
hedeboe
hej
hel
heller
helligdagslov
helt
heltberg
hen
hende
hendes
henover
henvisningsoversigt
henvisningsoversigten
henvisningsoversigtens
henvisningsoversigterne
henvisningsoversigternes
her
herefter
heri
hermed
herpå
hilmar
hindrup
homann
hos

Mikkel Vayland Hansen

hun
husmark
hvad
hvem
hver
hvilke
hvilken
hvilkes
hvis
hvor
hvordan
hvorefter
hvorfor
hvorfra
hvorhen
hvor
hvorimod
hvornår
hvorved
i
igen
igennem
ikke
imellem
imens
imod
importafgift
importafgiften
importafgiftens
importafgifter
ind
indtil
industriminister
industriministeren
industriministerens
ingen
integrationsminister
integrationsministeren
integrationsministerens
intet
ja
jahn
jamen
jane
jeg
jer
jeres
jerup

Mikkel Vayland Hansen

jo
jobskabelsesloven
johannesskolen
junior
kallesøe
kan
karensdag
karensdage
karensdagen
kasseoverskud
kasseoverskuddet
kd
keld
khader
kildeskat
kildeskatten
kildeskattens
kildeskatter
kindberg
kjærsgaard
klint
kofod
kolstrup
kom
komme
kommer
kommunikationsminister
kommunikationsministeren
kommunikationsministerens
kornordning
kornordningen
kornordninger
kosovo
kreditstramning
kreditstramningen
kreditstramninger
krf
kristendemokrater
kristendemokraterne
kristendemokraternes
kristine
kun
kunne
lad
længere
læremangel
læremangelen
lahn

Mikkel Vayland Hansen

langballe
langs
lav
lave
lavet
lawaetz
legarth
leroy
lidegaard
lidt
lige
ligesom
lille
lissabontraktaten
lundholt
må
majbrit
man
mand
mange
markedsminister
markedsministeren
markedsministerens
markedssekretariatet
markedssekretariatets
martet
martinez
måske
med
meget
mellem
men
mens
mere
meroms
meromsen
merværdiafgift
merværdiafgiften
merværdiafgifter
messerschmidt
mest
mig
miljøminister
miljøministeren
miljøministerens
min
mindre
mindst

Mikkel Vayland Hansen

mine
mining
mit
mod
nær
næste
næsten
når
naser
ned
nej
nemlig
ni
nicetraktaten
niebuhr
nødgaard
noer
nogen
nogensinde
noget
nogle
nok
nordek
nordqvist
nordvietnam
nu
ny
nyt
ødt
oeec
og
også
okay
om
ømann
omkring
omsætningsskat
omsætningsskatten
op
os
otte
over
overalt
øvrigt
på
påalign
pelle
pernille

Mikkel Vayland Hansen

pga.
politikasse
politikassen
politikasserne
politikassernes
poulsgaard
prehn
prisstoppet
prisstoppets
pristop
rahbæk
regeringskonference
regeringskonferencen
regeringskonferencens
reintofts
retoft
retsforbundet
retsforbundets
ritta
rohrsted
rosenkrantz
rosk
rune
så
sådan
således
samme
sammen
sams
sandy
saunte
schak
schengen
schj
sdi
se
seks
selv
selvom
senere
ser
ses
sf's
siden
sig
sige
sin
sine

Mikkel Vayland Hansen

sit
sjursen
skaarup
skal
skattefradragsregel
skattefradragsreglen
skattefradragsregler
skatteminister
skatteministeren
skatteministerens
skattestop
skattestoppet
skattestoppets
skræppenborg
skrumsager
skulle
socialindkomst
socialindkomsten
socialindkomster
sohn
som
sophie
søvndal
stadig
statsbanepersonale
statsbanepersonalet
statsbanepersonalets
statsmin.s
stjernholm
stor
store
storlufthavn
storlufthavne
storlufthavnen
stubbjær
sundhedsminister
sundhedsministeren
sundhedsministerens
sydamager
synes
syntes
syv
tag
tage
tatovere
tatoverer
tatoivering
tatoivering

Mikkel Vayland Hansen

tatoveringer

temmelig

theil

theil

thi

thorndahl

thulesen

ti

tidenden

tidligere

til

tilbage

tindemans

tit

to

tre

uafhængig

uafhængige

uafhængiges

ud

uden

udover

ufg

under

undtagen

vækstfremmere

vær

være

været

var

ved

velfærdministerens

velfærdsminister

velfærdsministeren

vestager

vi

via

vibjerg

vil

ville

vivike

voigt

vor

vore

vores

vs

wedell

westergaard

Mikkel Vayland Hansen

wilhelm
yildiz

Link: <https://regex101.com/r/WNFVKt/1>

Open Refine:

Does OpenRefine alter the raw data during sorting and filtering?

No. OpenRefine does not alter the raw data, since it is used to filter the data and sort it out. The data is only changed if the user uses functions as split or replace.

Which two months are reported as the most water-deprived/dryest by the interviewed farmer households?

Step 1: Create text facet under the category “Months_no_water” and press “sort by count”

Step 2: Go to “Edit cells” -> “transform” and transform this:


```
value.replace("[", "").replace("]", "").replace("", ",")
```

Step 3: Go to “Edit cells” -> “split multi-valued cells” and write “,” under “replace”

Step 4: Leave out the spaces between values: go to “edit cells” -> “transform” and write:

```
value.replace(" ", "")
```

Conclusion: It is now clear that it is October and September, that are the driest months:



10 most frequent occupations (Unmarried women, age 20-30)

Step 1: Create a text facet under the category “køen” and then only include “kvinde”

Step 2: Create a text facet under the category “civilstand” and then only include “ugift”


Step 3: In the category “alder” go to “edit cells” -> “common transform” -> “to number”

Step 4: Scale down the number in “alder” to 20-30

Step 5: Create a text facet under the category “erhverv” and cluster the different occupations using the “key collision” method and the “metaphone 3” key function :

Merge?	Values in cluster	New cell value	Cluster size	Row count
☐	☐ inderste og væverpige (2 rows) ☐ inderste og vævpige ☐ inderste og væver	inderste og væverpige	3	4
☐	☐ ernærer sig af syning (3 rows) ☐ ernærer sig ved at spinde (2 rows) ☐ ernærer sig af haandarbejde	ernærer sig af syning	3	6
☐	☐ syge pige ☐ syepige	syge pige	2	2
☐	☐ inderste og spindekone ☐ inderste og spinderske	inderste og spindekone	2	2
☐	☐ skræderpige (3 rows) ☐ skrædderpige	skræderpige	2	4

Step 6: Observe to the 10 most frequent occupations:



Conclusion: These are the top 10 most frequent occupations. - The ones with a red line are marked, because these are not seen as an actual occupation. For instance "lives off her own means"